Fase 2 — limpeza de dados e análise exploratória

Projeto extensionista: INCT SiMAI e nível do Guaíba. Preparado em 26/10/2026. Os procedimentos completos estão nos notebooks 01, 02 e 03.

1. Preparação do JSON do INCT

O JSON original foi preservado e transformado em 6.674 linhas (71 níveis × 94 bairros). com uma linha por nível e bairro. Nenhum nível ou bairro está ausente. O total de prédios e a população de cada bairro permanecem constantes entre níveis. O arquivo limpo está em dados/processados/inct_simai_limpo.csv.

A fonte arredonda para cima o percentual de prédios afetados e a população estimada. Essa regra foi identificada antes das correções e mantida; uma coluna adicional registra o percentual exato. A população afetada é estimada sob a hipótese de distribuição uniforme de moradores entre prédios, inclusive não residenciais.

2. Inconsistências encontradas e decisões

Onde aparece	Problema observado	Tratamento e justificativa
Arquipélago; 3,0, 3,5, 4,0, 4,1, 4,5, 5,0 e 5,3 m	Sete valores isolados desviam da contagem 4680, presente em 64 dos 71 níveis; surgem quedas quando o nível sobe.	Substituídos pela moda 4680; preservar valores originais na auditoria.
Espírito Santo; 3,0–3,4 m	Contagens 633–637 caem para 25 em 3,5 m.	Imputação pelo primeiro valor plausível (25); trecho marcado como incerto.
Espírito Santo; 4,7 m	Pico isolado de 2101 entre 46 e 47.	Interpolação linear entre níveis adjacentes: 47.
Centro Histórico; 9,7–9,8 m	Zeros entre 2050 (9,6 m) e 2130 (9,9 m).	Interpolação linear: 2077 e 2103.
Lageado; 8,1 m; Rubem Berta; 8,8 m	Zero isolado entre valores positivos.	Interpolação linear: 109 e 269, respectivamente.
Boa Vista do Sul; 7,2–7,3 m	Percentual 29, mas 686/2450 exige 28 pela regra da fonte.	Recalcular percentual e população afetada a partir das contagens.

Foram alteradas 17 contagens de prédios e 24 campos derivados, totalizando 41 alterações rastreadas em dados/processados/auditoria_inct.csv. Depois do tratamento não restam quedas de prédios afetados dentro de cada bairro.

3. Série ANA

O XML da estação 87450020 foi preservado com 5.551 registros. A grade de 15 minutos entre 03/05 e 30/06/2024 tem 5.664 horários: 5.444 com nível válido. 107 registros com nível vazio e 113 horários ausentes do XML. Valores em centímetros foram convertidos para metros. Lacunas foram mantidas. sem interpolação. Nenhuma medição foi removida como outlier sem evidência suficiente.

Pico observado no recorte: 4,17 m em 05/05/2024 às 05h30. Trata-se da série da estação 87450020 no referencial corrigido. A base ANA foi auditada em separado, sem classificar diferenças com a simulação do INCT como erros.

4. EDA e resultado salvo

O notebook 03 contém oito gráficos comentados e exportados em resultados/figuras: cinco da simulação INCT e três da série ANA. No cenário 5.3 m. o JSON limpo estima 138.414 pessoas. 53.981 prédios e 36 bairros atingidos. Esses números são estimativas da simulação.

O esboço das duas telas está em relatorios/wireframe.md. A Tela 1 usa exclusivamente o JSON limpo; a Tela 2 usa a série ANA. A ligação temática é o evento de 2024, com fontes e data de coleta visíveis.

5. Reprodutibilidade e limites

Execute python -m scripts.preparar_dados na raiz do repositório. O XML bruto permite repetir a limpeza sem nova coleta caso o serviço legado da ANA seja descontinuado. Data e URL estão no CSV de metadados. O uso de IA está registrado no README.